


DL의 이론적 배경

밑바닥.. (물고기) Ch2-5

주제

- 퍼셉트론 Ch2
- 신경망 Ch3
- 신경망학습 Ch4
- 오차역전파법 Ch5



Perceptron

물고기 Ch2

Model of Neuron






FIGURE 1.2 The pyramidal cell.



퍼셉트론 Perceptron

- 신경망의 수학적 모형





그림 4.2 퍼셉트론의 구조

출처: 패턴인식

퍼셉트론

- 원: 뉴런 (node, or vertex)
- 선: 시냅스 (link, or edge)
- x_1, x_2 : 입력
- w_1, w_2 : 가중치
- θ : 임계값
- y : 출력



$$y = \begin{cases} 0 & (w_1 x_1 + w_2 x_2 \leq \theta) \\ 1 & (w_1 x_1 + w_2 x_2 > \theta) \end{cases}$$

입력2 → 출력1 퍼셉트론의 예

- 퍼셉트론으로 논리연산을 할 수 있음
 - AND
 - NAND
 - OR
- 위 역할을 수행할 수 있는 (w_1, w_2, θ) 벡터를 찾는 문제
 - AND: $(0.5, 0.5, 0.7)$
 - NAND: $(-1, -1, -1)$
 - OR: $(0.5, 0.5, 0.3)$

x_1	x_2	y
0	0	0
1	0	0


x_1	x_2	y
0	0	1
1	0	1

x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	1

1
0


임계값 \rightarrow bias (편향)

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$




$$y = \begin{cases} 0 & (b + w_1x_1 + w_2x_2 \leq 0) \\ 1 & (b + w_1x_1 + w_2x_2 > 0) \end{cases}$$

- $b := -\theta$




기하학적 의미

- 단일 퍼셉트론은 선형 구분선을 의미함
 - 입력수 = 차원수
 - 즉, 입력 퍼셉트론이 2개인 경우 2차원 선형 구분선 (즉, 직선)을 의미
 - n개인 경우 n차원 버전의 평면으로된 구분면 (hyperplane)



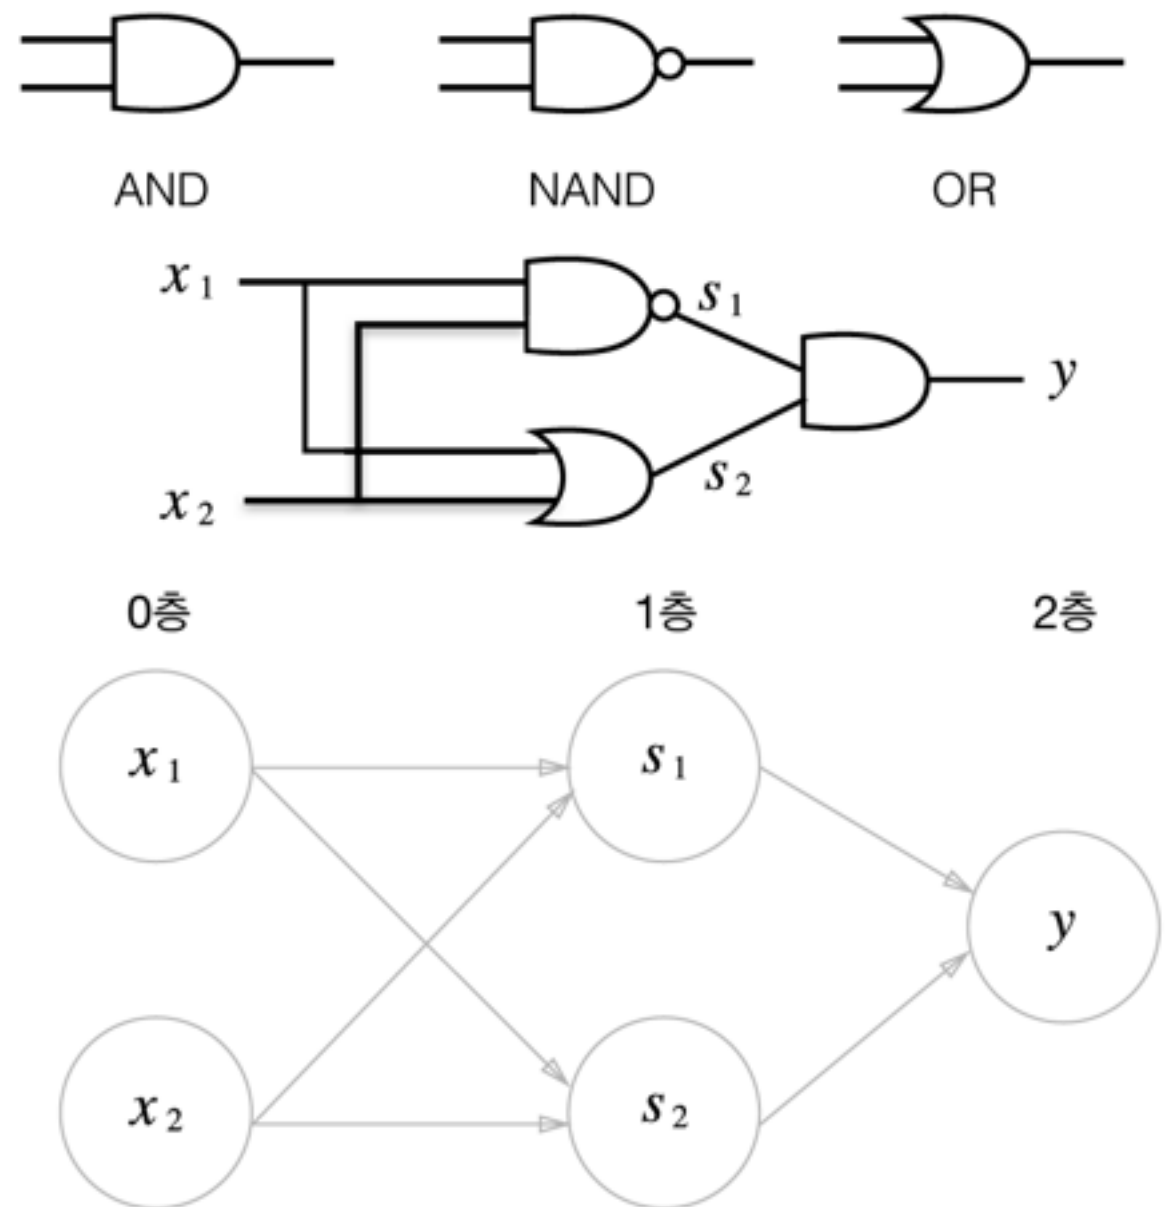
다층 퍼셉트론 (MLP) Multi-Layer Perceptron

- XOR의 경우 output을 가르키는 선형 구분선을 만들 수 없음
- 하지만 AND, NAND, OR 세 퍼셉트론을 조합하여 XOR을 구현할 수 있음!



XOR by MLP

- XOR (x_1, x_2):
 - $s_1 = \text{NAND}(x_1, x_2)$
 - $s_2 = \text{OR}(x_1, x_2)$
 - return $\text{AND}(s_1, s_2)$
- 2 Layer Perceptron
- 활성화함수들의 합성함수의 개념과 동등함



NANDs can do everything

- NAND의 유한한 합성으로 컴퓨터의 모든 연산을 재현할 수 있음
 - The Elements of Computing Systems, MIT Press 2005
- Sigmoid 함수를 활성화함수로 사용할 경우 임의의 함수를 2층 퍼셉트론으로 표현할 수 있음이 수리적으로 증명되어 있음 (이론적으로는!)
 - 현실적으로는 weight 를 찾는 것이 어려운 문제

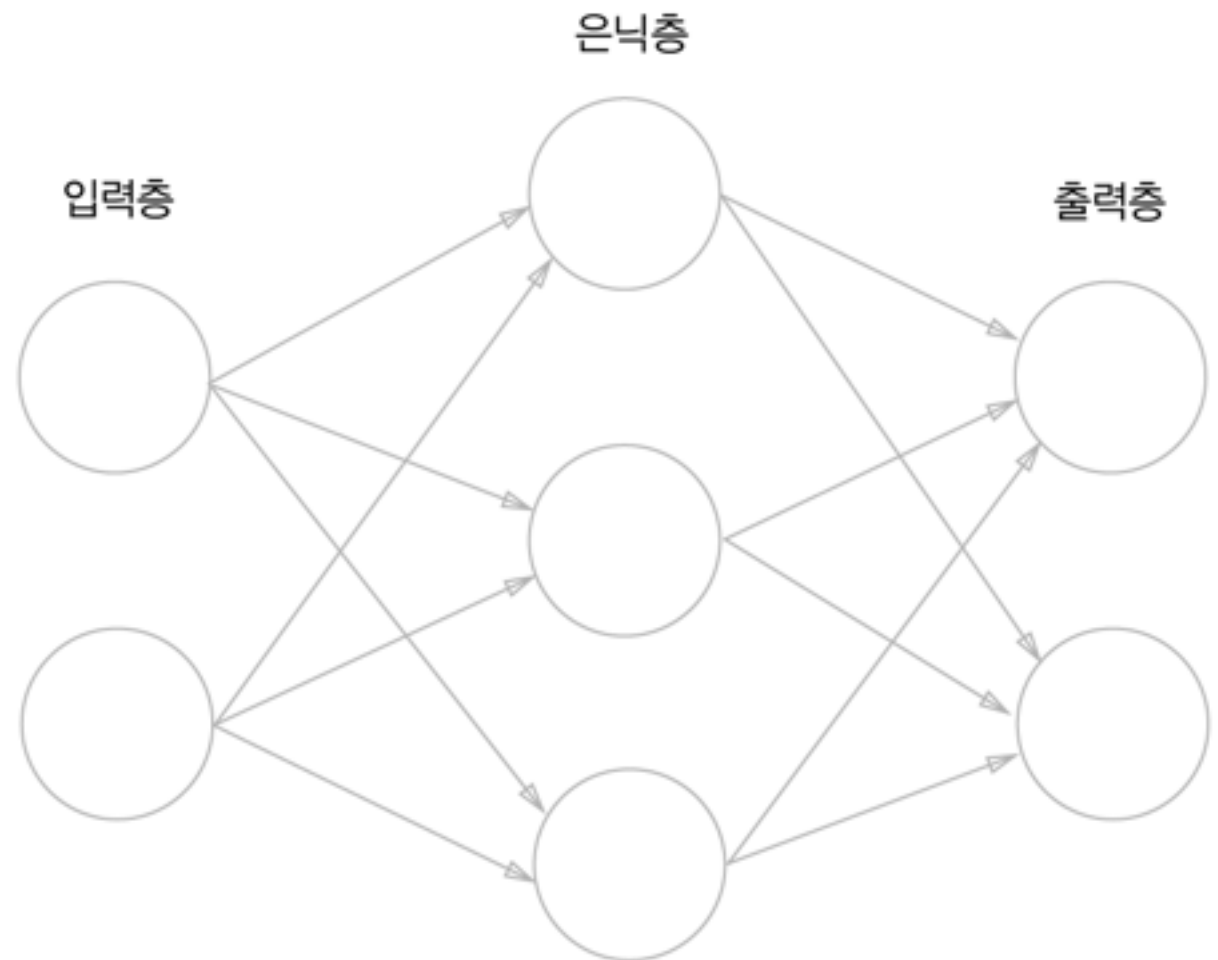
NN: Neural Networks

신경망


물고기 Ch3

신경망 구조

- input layer: 입력 (data)
- hidden layer: 연산
- output layer: 결과




3층 신경망



사이토 고키 (2017)

신경망 Neural Networks




<http://neuromastersoftware.com/neural-network-theory-introduction/>

Activation Function

- $h(x)$
 - x : input으로 들어온 신호의 가중합
 - h : 가중합을 통해 activation 여부를 결정할 함수
- 다양한 activation 함수들 존재
 - step function
 - sigmoid function
 - relu function 등


$$y = h(b + w_1x_1 + w_2x_2)$$

$$h(x) = \begin{cases} 0 & (x \leq 0) \\ 1 & (x > 0) \end{cases}$$




활성함수

Activation Functions




Sigmoid

http://www.saedsayad.com/artificial_neural_network.htm



Step

http://en.wikibooks.org/wiki/Artificial_Neural_Networks/Activation_Functions#Continuous_Log-Sigmoid_Function



ReLU


<http://cs231n.github.io/neural-networks-1/>

And many others...

<https://image.slidesharecdn.com/usuconference-deeplearning-160418191119/95/introduction-to-deep-learning-7-638.jpg?cb=1461006739>

Step Function


- 가로축 변수: 입력가중합
- 세로축 변수: 출력값
- 각 노드는 0 혹은 1의 값만을 발생시킴
- 미분 불가능
 - 계산적으로 좋지 않은 속성
 - 역함수 없음



Sigmoid Function

- S - shaped graph
- 각 노드는 0~1 사이의 실수를 발생시킴
- 미분 가능함!
 - 계산적으로 매우 좋은 특성임
- 특정 상황에서 step function보다 나을 수 있음
 - 미분 불가능한 함수는 다루기가 어려움


$$h(x) = \frac{1}{1 + \exp(-x)}$$



Rectified Linear Unit : ReLU Function

$$h(x) = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

- 0 이하일 경우 무시
- 0 이상일 경우 입력값을 그대로 전달
- 0에서 미분 불가능
- 제한적인 미분 가능성 (0 이상) 존재



N차원 배열 (tensor?)

- 벡터: 숫자를 1차원 직선으로 배열한 것
- 행렬: 숫자를 2차원 직사각형으로 배열한 것
- 3차원 배열: 숫자를 3차원 직육면체로 배열한 것
- N차원 배열: 숫자를 N차원 직육면체(hyper cube)로 배열한 것
- Numpy 구현:
 - `np.array(...)`

Inner Product

$$\mathbf{u} \bullet \mathbf{v} := \sum_i^n u_i v_i \in \mathbb{R}^1$$

- Vector Inner Product

- 잘 알고 있는 그것.

- Matrix Inner Product

- 2D: 잘 알고 있는 그것
- nD: 잘 모를 그것..

$$\mathbf{A} = \begin{pmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ A_{21} & A_{22} & \cdots & A_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nm} \end{pmatrix} = \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_n \end{pmatrix},$$

$$\mathbf{B} = \begin{pmatrix} B_{11} & B_{12} & \cdots & B_{1p} \\ B_{21} & B_{22} & \cdots & B_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ B_{m1} & B_{m2} & \cdots & B_{mp} \end{pmatrix} = (\mathbf{b}_1 \quad \mathbf{b}_2 \quad \cdots \quad \mathbf{b}_p)$$

`numpy.dot(a, b, out=None)`

Dot product of two arrays.

For 2-D arrays it is equivalent to matrix multiplication, and for 1-D arrays to inner product of vectors (without complex conjugation). For N dimensions it is a sum product over the last axis of *a* and the second-to-last of *b*:

```
dot(a, b)[i,j,k,m] =  
sum(a[i,j,:] * b[k,:,m])
```


$$\mathbf{AB} = \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_n \end{pmatrix} (\mathbf{b}_1 \quad \mathbf{b}_2 \quad \cdots \quad \mathbf{b}_p) = \begin{pmatrix} (\mathbf{a}_1 \cdot \mathbf{b}_1) & (\mathbf{a}_1 \cdot \mathbf{b}_2) & \cdots & (\mathbf{a}_1 \cdot \mathbf{b}_p) \\ (\mathbf{a}_2 \cdot \mathbf{b}_1) & (\mathbf{a}_2 \cdot \mathbf{b}_2) & \cdots & (\mathbf{a}_2 \cdot \mathbf{b}_p) \\ \vdots & \vdots & \ddots & \vdots \\ (\mathbf{a}_n \cdot \mathbf{b}_1) & (\mathbf{a}_n \cdot \mathbf{b}_2) & \cdots & (\mathbf{a}_n \cdot \mathbf{b}_p) \end{pmatrix}$$

Matrix Inner Product: Example


$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

$\begin{matrix} & 1 \times 5 + 2 \times 7 \\ & \swarrow \quad \searrow \\ A & & B \\ \nwarrow \quad \nearrow \\ & 3 \times 5 + 4 \times 7 \end{matrix}$

- Numpy: `np.dot(A,B)`
- $(m \times n) \cdot (n \times p) = (m \times p)$



신경망 \Rightarrow 선형대수



$$\begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix}$$

$$X \quad W \quad = \quad Y$$

$$\begin{matrix} 2 & 2 \times 3 & 3 \\ (1 \times 2) \bullet (2 \times 3) = (1 \times 3) \end{matrix}$$

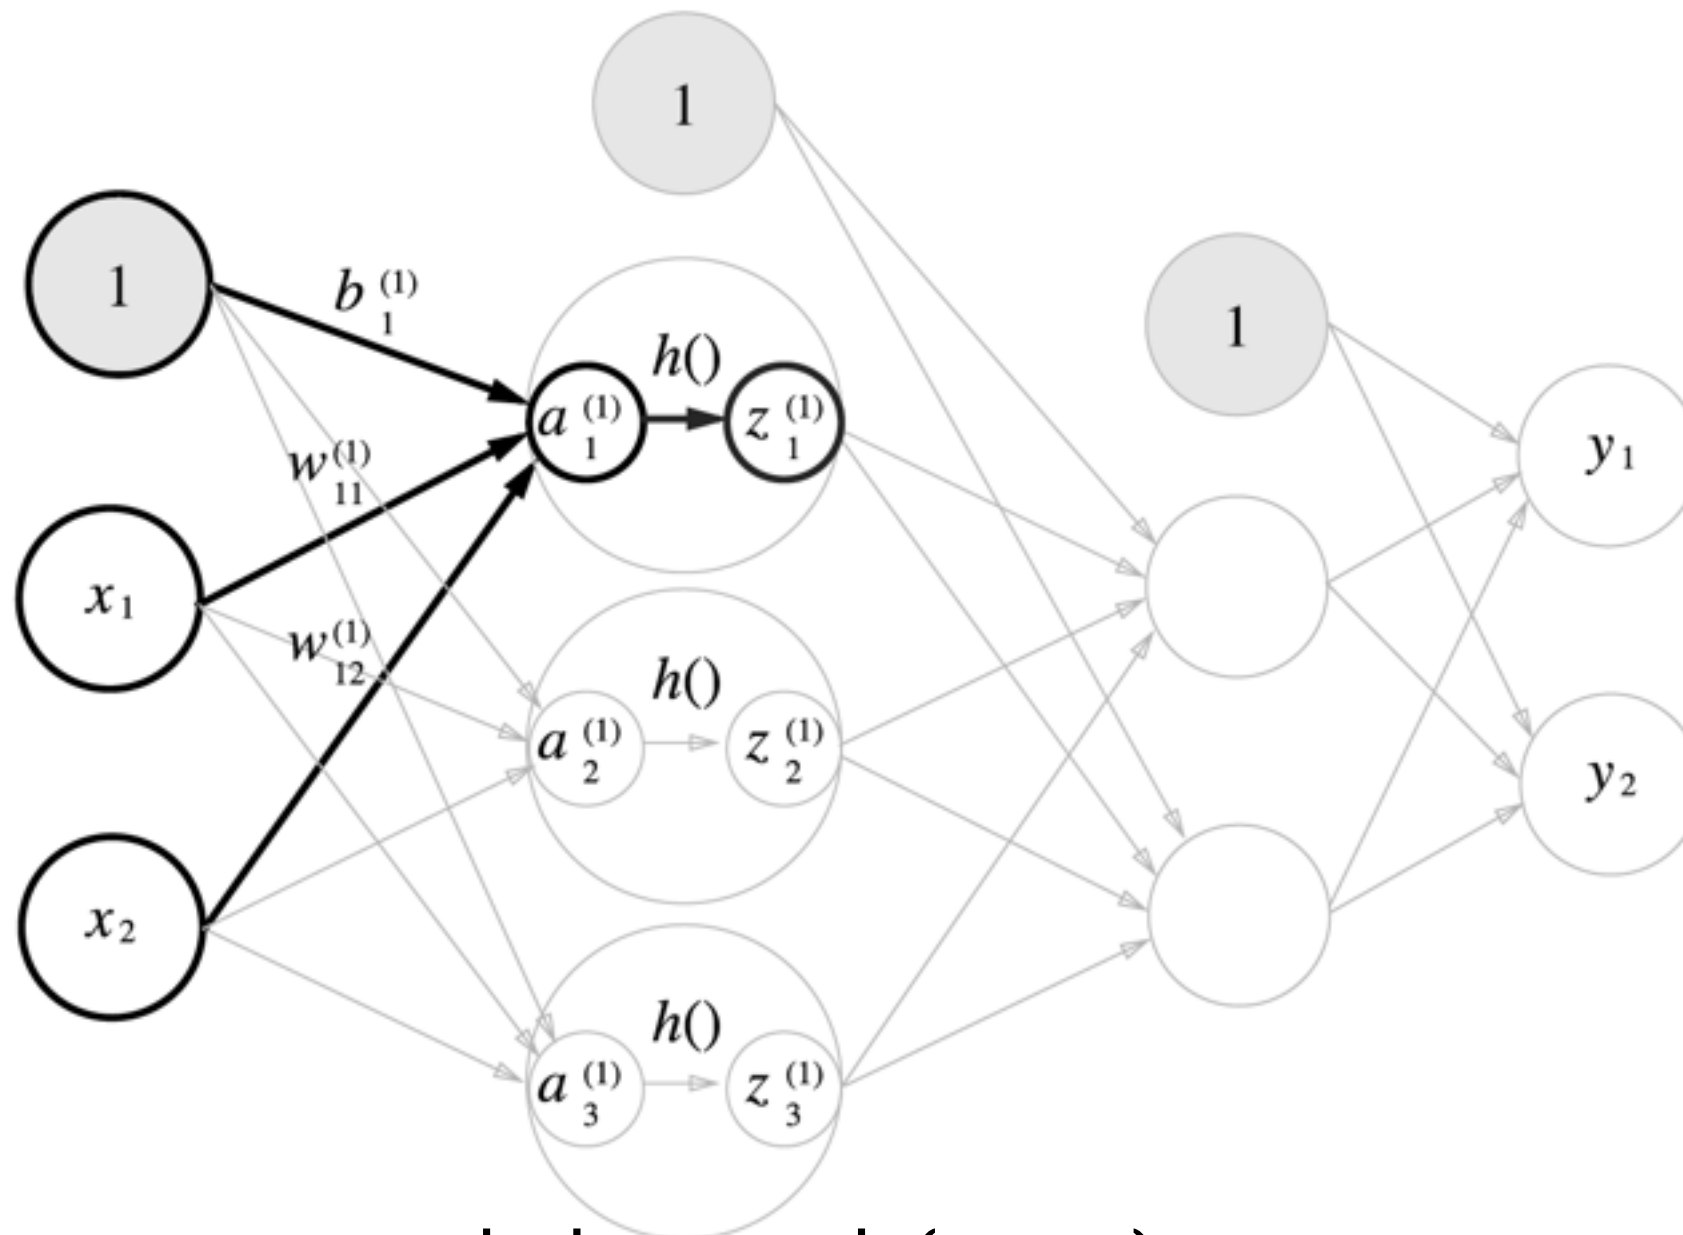
일치

$$\begin{pmatrix} x_1 & x_2 \end{pmatrix} \bullet \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix} = \begin{pmatrix} y_1 & y_2 & y_3 \end{pmatrix}$$

사이토 고키 (2017)

$$A^{(1)} = X \bullet W^{(1)} + B^{(1)}$$

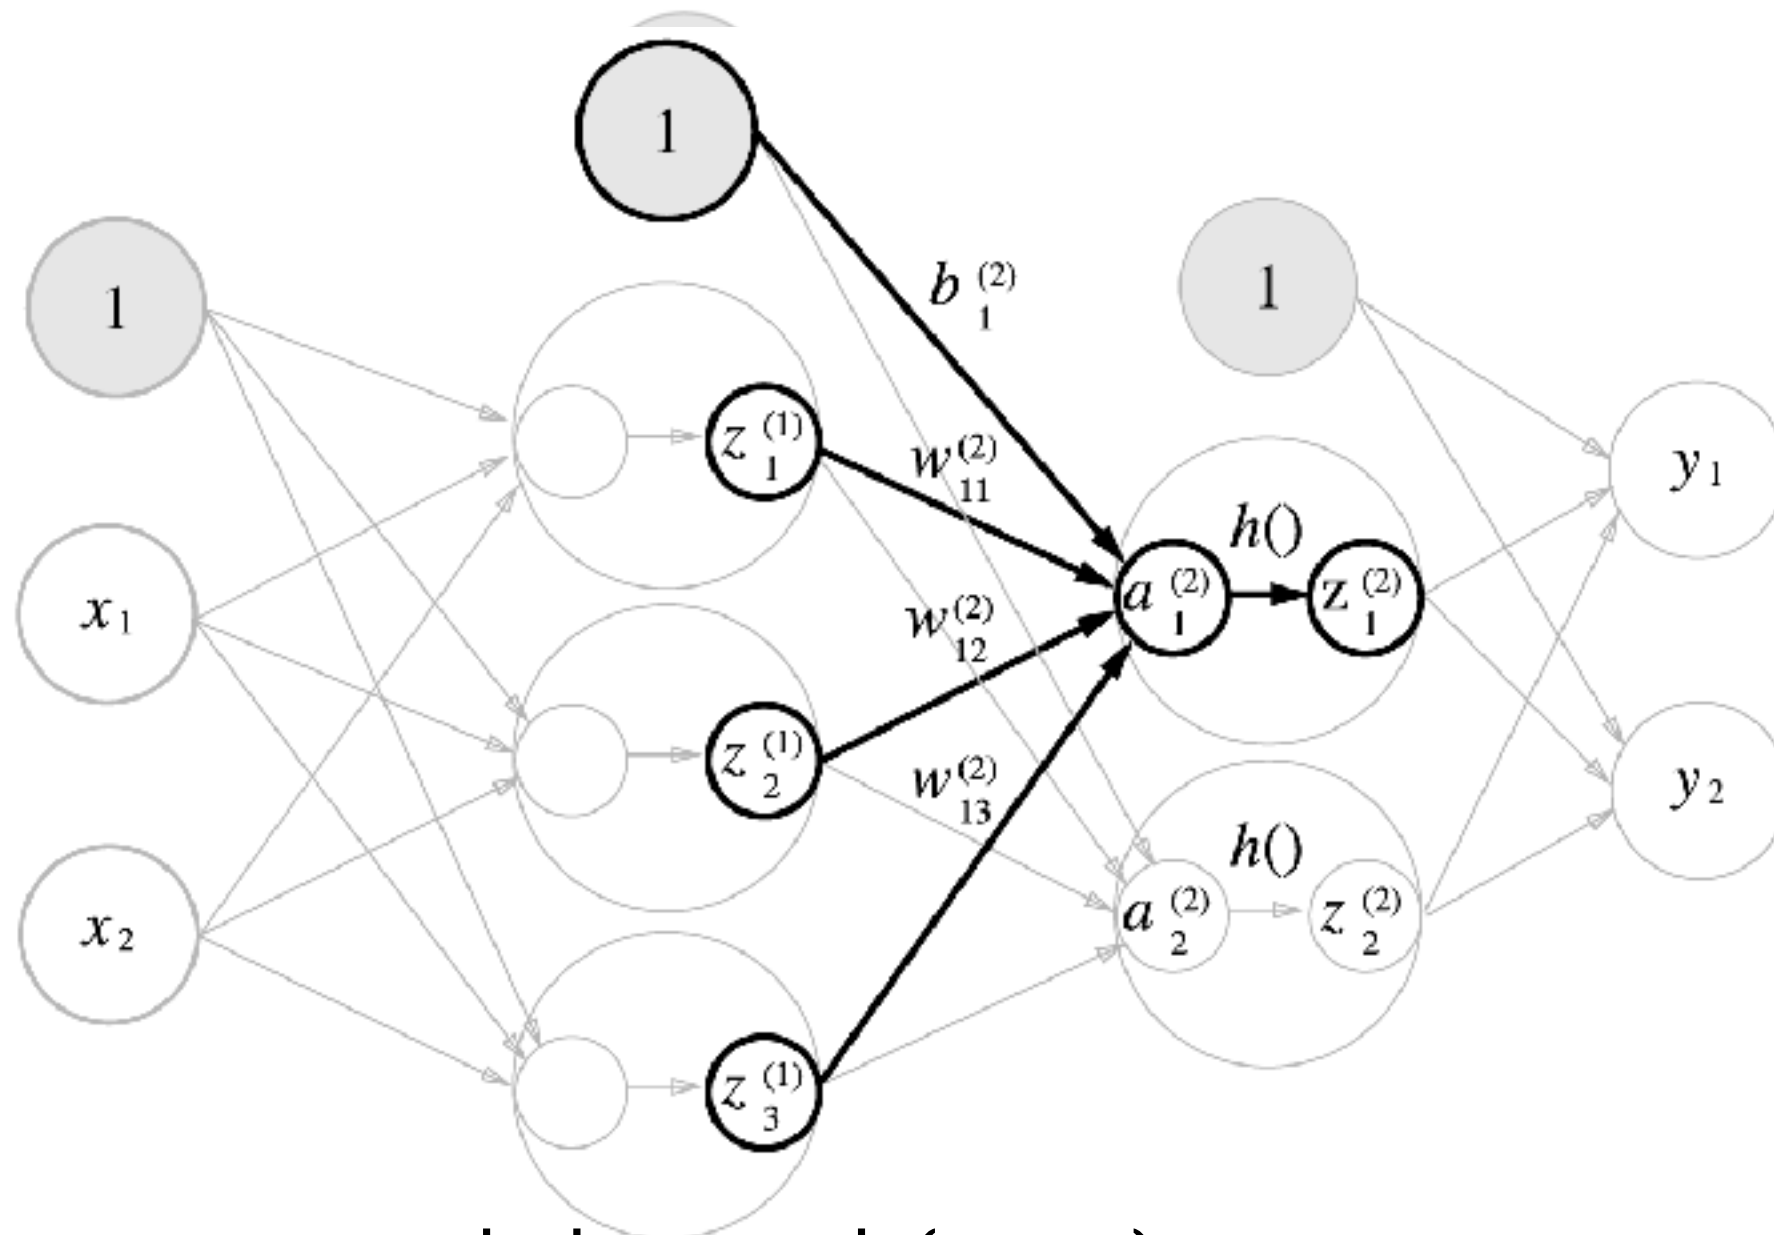
$$\begin{pmatrix} a_1^{(1)} & a_2^{(1)} & a_3^{(1)} \end{pmatrix} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \bullet \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} & w_{13}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} & w_{23}^{(1)} \end{pmatrix} + \begin{pmatrix} b_1^{(1)} & b_2^{(1)} & b_3^{(1)} \end{pmatrix}$$



사이토 고키 (2017)

$$A^{(1)} = X \bullet W^{(1)} + B^{(1)}$$

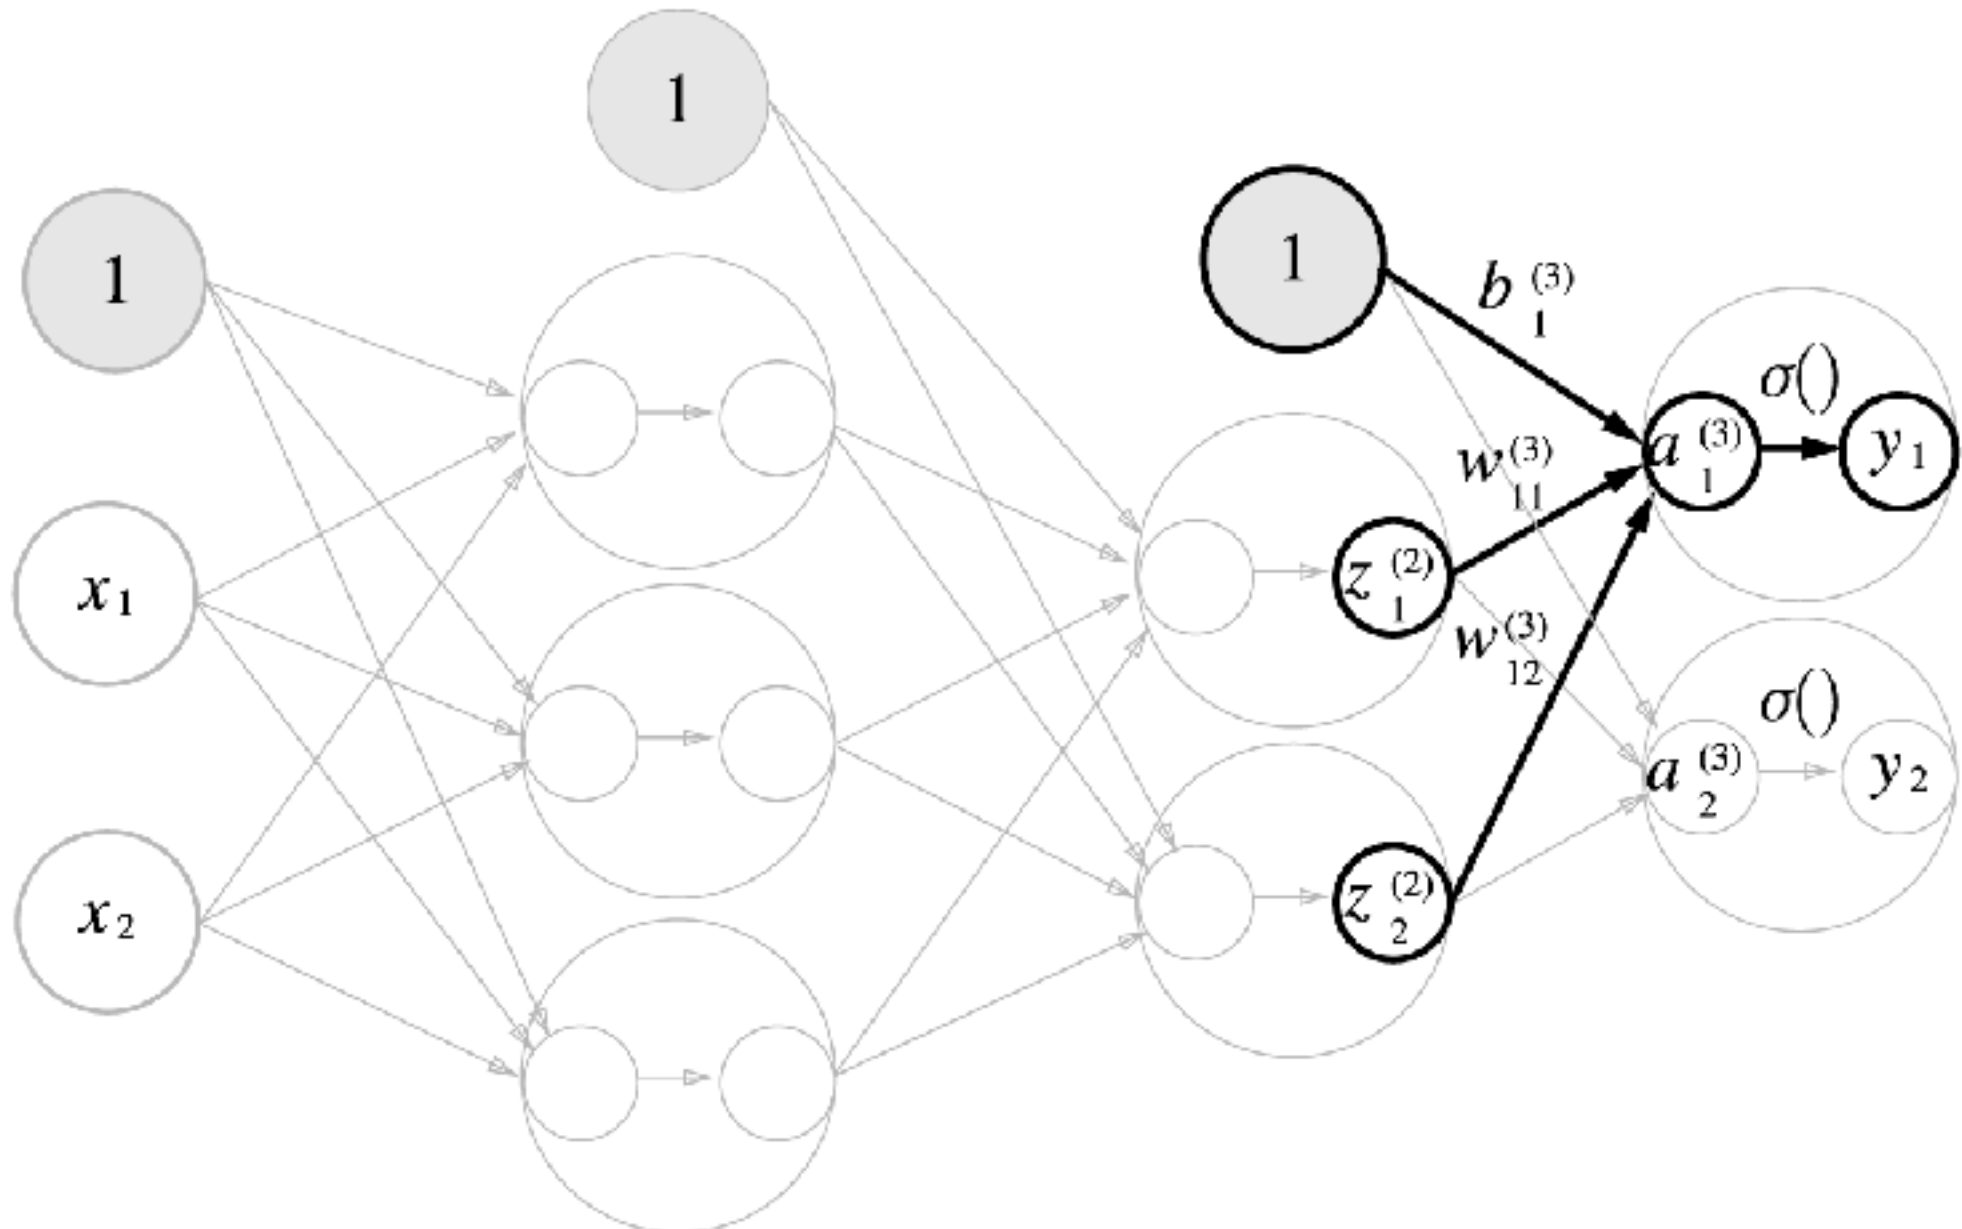
$$\begin{pmatrix} a_1^{(1)} & a_2^{(1)} & a_3^{(1)} \end{pmatrix} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \bullet \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} & w_{13}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} & w_{23}^{(1)} \end{pmatrix} + \begin{pmatrix} b_1^{(1)} & b_2^{(1)} & b_3^{(1)} \end{pmatrix}$$



사이토 고키 (2017)

$$A^{(1)} = X \bullet W^{(1)} + B^{(1)}$$

$$\begin{pmatrix} a_1^{(1)} & a_2^{(1)} & a_3^{(1)} \end{pmatrix} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \bullet \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} & w_{13}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} & w_{23}^{(1)} \end{pmatrix} + \begin{pmatrix} b_1^{(1)} & b_2^{(1)} & b_3^{(1)} \end{pmatrix}$$




사이토 고키 (2017)

출력층의 활성화함수

- 기계학습 문제에 따라 달라짐
 - 회귀 (regression) \Rightarrow identity function
 - 출력층의 수: 추정하고자 하는 벡터의 차원수
 - 분류 (classification) \Rightarrow softmax function
 - 출력층의 수: 분류하고자 하는 것의 갯수

Identity function


- $\sigma(x) = x$



Softmax function

- 출력층의 모든 값(y_k)의 합이 1
 - $0 \leq y_k \leq 1$
 - $\sum y_k = 1$
 - 각 출력의 확률로 해석 가능
 - 지수이기 때문에 계산시 불안정한 문제 발생 (overflow 문제)
- 계산량 부담으로 추론단계에서는 그냥 $\max(y_k)$ 를 사용하기도 함
 - 학습 단계에서는 softmax 사용

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$



Resolving Overflow

- def softmax(a):
 - c = np.max(a)
 - exp_a = np.exp(a-c)
 - sum_exp_a = np.sum(exp_a)
 - return exp_a / sum_exp_a

$$\begin{aligned} y_k &= \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)} = \frac{C \exp(a_k)}{C \sum_{i=1}^n \exp(a_i)} \\ &= \frac{\exp(a_k + \log C)}{\sum_{i=1}^n \exp(a_i + \log C)} \\ &= \frac{\exp(a_k + C')}{\sum_{i=1}^n \exp(a_i + C')} \end{aligned}$$

신경망 학습

물고기 Ch4

오차역전파법 Backpropagation

물고기 Ch5